

Министерство цифрового развития, связи и массовых коммуникаций Российской
Федерации
Ордена Трудового Красного Знамени
федеральное государственное бюджетное образовательное учреждение высшего
образования
«Московский технический университет связи и информатики»

Кафедра «Прикладная инженерия»

Отчет по учебно-технологической практике

по теме:

**«Разработка учебного прототипа системы прогнозирования и обнаружения
аномалий во временных рядах»**

Выполнила:

студентка группы М092501(72)

Степанова Дарина Викторовна

Руководитель практики:

Мосева Марина Сергеевна

Москва, 2026

Введение

Временной ряд представляет собой набор наблюдений, упорядоченных по времени. Каждое значение такого ряда связано с конкретным моментом или интервалом времени. Примерами временных рядов являются показания температурных датчиков, данные об энергопотреблении, нагрузка сервера, сетевой трафик, телеметрия оборудования, производственные показатели и другие данные, изменяющиеся во времени.

В рамках практики необходимо разработать учебный прототип системы, выполняющей две основные функции. Первая функция связана с прогнозированием будущих значений временного ряда на основе имеющихся наблюдений. Вторая функция связана с обнаружением аномальных значений или аномальных интервалов, которые отличаются от обычного поведения данных. Под аномалиями в данной работе понимаются резкие выбросы, необычные отклонения, нетипичные интервалы или иные изменения, которые могут указывать на сбой, ошибку измерения, нестандартный режим работы объекта или иное значимое событие.

Целью учебной практики является разработка прототипа системы для анализа временных рядов, выполняющего две основные функции: прогнозирование будущих значений временного ряда и обнаружение аномальных значений или интервалов, отличающихся от обычного поведения данных.

В ходе работы были решены следующие задачи:

- Выбор и загрузка набора данных
- Предварительная обработка данных
- Визуальный анализ временного ряда
- Построение базовой модели прогнозирования
- Реализация дополнительной модели прогнозирования
- Реализация методов обнаружения аномалий
- Оценка полученных результатов
- Интерпретация результатов

Выполнение

1. Подготовка данных

Для выполнения работы был выбран датасет Numenta Anomaly Benchmark (NAB) [1, 10]. NAB представляет собой бенчмарк для оценки алгоритмов обнаружения аномалий в потоковых данных реального времени и содержит более 50 размеченных временных рядов из реальных и искусственных источников [10].

Выбранный файл: «Twitter_volume_AAPL.csv» из категории «realTweets» – данные представляют собой временной ряд объема твитов (количество упоминаний) по акциям компании Apple (AAPL) в социальной сети Twitter.

Состав данных:

- Временная метка (timestamp): дата и время каждого наблюдения с интервалом 5 минут
- Значение (value): количество твитов, упоминающих AAPL за 5-минутный интервал

Характеристики данных:

- Период: с 26 февраля по 23 апреля 2015 года
- Частота: 5-минутные интервалы
- Объем данных: 15 902 наблюдения

Анализ объема твитов по компании позволяет:

- Оценивать общественный интерес к компании в реальном времени
- Выявлять аномальные всплески активности, связанные с важными событиями
- Прогнозировать влияние социальных медиа на фондовый рынок

В контексте данного датасета аномалиями считаются резкие всплески объема твитов, необычные пики активности, значительно отклоняющиеся от статистической нормы. Такие аномалии могут указывать на выход важных новостей, финансовые отчеты, технические сбои или вирусное распространение информации.

Данные полные, пропусков не обнаружено. Для удобства были переведены даты в формат datetime (рис. 1-2). Статистика показывает высокую волатильность: среднее 85.55, но максимум 13,479. 75% значений ≤ 76 , что указывает на наличие редких, но очень высоких пиков.

#	Column	Non-Null Count	Dtype
...			
0	timestamp	15902 non-null	object
1	value	15902 non-null	int64
			dtypes: int64(1), object(1)
			memory usage: 248.6+ KB

Статистика:

	value
count	15902.000000
mean	85.552320
std	321.050721
min	0.000000
25%	29.000000
50%	47.000000
75%	76.000000
max	13479.000000

Столбцы: ['timestamp', 'value']

Рисунок 1 – Статистика по датасету

Период данных: с 2015-02-26 21:42:53 по 2015-04-23 02:47:53			
Количество записей: 15902			
Пропуски в 'value': 0			
Дубликаты временных меток: 0			
После обработки: 15902 записей			
	timestamp	value	value_scaled
0	2015-02-26 21:42:53	104	0.057462
1	2015-02-26 21:47:53	100	0.045003
2	2015-02-26 21:52:53	99	0.041888
3	2015-02-26 21:57:53	154	0.213206
4	2015-02-26 22:02:53	120	0.107300

Рисунок 2 – Подготовка данных

2. Методология

2.1 Инструменты и технологии

Работа выполнена в среде Google Colab с использованием следующих библиотек:

- pandas, numpy – обработка и анализ данных
- matplotlib, seaborn – визуализация
- scikit-learn – машинное обучение, метрики оценки
- statsmodels – ARIMA моделирование
- json для обработки разметки

2.2 Методы прогнозирования

2.2.1 Базовая модель (Naive)

В качестве базовой модели использовалось прогнозирование предыдущим значением (naïve forecast). Данный подход предполагает, что наилучшим прогнозом для следующего наблюдения является последнее известное значение. Несмотря на простоту, эта модель служит важным бенчмарком для сравнения более сложных алгоритмов.

2.2.2 Скользящее среднее (Moving Average)

Использовались скользящие средние с окнами 7 и 30 дней. Метод основан на усреднении значений за предыдущий период, что позволяет сгладить краткосрочные колебания и выявить общий тренд.

2.2.3 ARIMA модель

ARIMA (Autoregressive Integrated Moving Average) – это класс моделей для прогнозирования временных рядов, сочетающий авторегрессию (AR), интегрирование (I) и скользящее среднее (MA) [2, 11].

AR часть показывает, что временной ряд регрессируется на свои прошлые значения. MA часть указывает, что ошибка прогноза является линейной комбинацией прошлых ошибок. I часть показывает, что данные были преобразованы путем дифференцирования для достижения стационарности [2].

2.3 Методы обнаружения аномалий

2.3.1 Z-score

Метод Z-score основан на оценке отклонения значения от среднего. Значение считается аномальным, если оно отличается от среднего более чем на заданный порог с учётом стандартного отклонения [3, 8]: $Z = (x - \mu) / \sigma$, где μ – среднее значение, σ – стандартное отклонение. При пороге $Z=3$ аномальными считаются значения, отклоняющиеся более чем на 3 стандартных отклонения.

2.3.2 IQR (межквартильный размах)

Метод IQR основан на определении типичного диапазона значений с использованием квартилей [3, 8]:

$$IQR = Q3 - Q1$$

$$Lower_bound = Q1 - 1.5 \cdot IQR$$

$$\text{Upper_bound} = Q3 + 1.5 \cdot \text{IQR}$$

Значения, выходящие за эти границы, считаются потенциальными аномалиями.

2.3.3 Ошибка прогноза ARIMA

Метод основан на сравнении фактических значений с прогнозными. Если ошибка прогноза оказывается слишком большой (превышает порог), соответствующая точка относится к аномальным. Порог определялся как: « $\text{mean}(\text{error}) + 2 \cdot \text{std}(\text{error})$ ».

3. Результаты

3.1 Визуальный анализ данных



Рисунок 3 – Визуальный анализ данных

Данные (рис. 3) показывают ежедневный объем твитов по компании. Данные нестационарны (среднее и дисперсия меняются во времени). Также наблюдаются резкие пики активности, что характерно для социальных сетей (например, значение 13,479 при среднем 85.55). Резкие пики могут быть связаны с важными новостями,

событиями или сезонными факторами. Есть периоды повышенной и пониженной активности. Скользящее среднее показывает общий тренд, который слегка растет к концу периода. Стандартное отклонение указывает на значительную волатильность данных (стандартное отклонение 321.05 намного превышает среднее). Это характерно для данных социальных медиа — редкие, но очень сильные всплески активности.

3.2 Прогнозирование

Был проведён тест Дики-Фуллера (ADF), который проверяет стационарность временного ряда:

$p\text{-value} = 0 < 0.05$ — следовательно, ряд стационарный (это хорошо для ARIMA)

ADF статистика = -20.2065 (очень отрицательная — отсюда также следует стационарность)

Также были построены графики ACF и PACF (рис. 4):

- ACF (Autocorrelation Function): автокорреляция — как значения зависят от прошлых

- PACF (Partial ACF): частная автокорреляция — прямая зависимость




Рисунок 4 — Графики ACF и PACF

Подбор параметров (рис. 5):

1. Перебираются комбинации $(p, 1, q)$ где $p, q \in \{0, 1, 2\}$
2. Выбирается модель с минимальным AIC (Akaike Information Criterion)
3. Лучшая модель: ARIMA(2, 1, 2) с AIC = 163678.60

Лучшая модель ARIMA(2, 1, 2) с AIC=163678.60

SARIMAX Results

Dep. Variable:	value	No. Observations:	12721
Model:	ARIMA(2, 1, 2)	Log Likelihood	-81834.301
Date:	Sun, 05 Jul 2026	AIC	163678.602
Time:	11:47:04	BIC	163715.857
Sample:	0	HQIC	163691.063
	- 12721		
Covariance Type:	opg		

	coef	std err	z	P> z	[0.025	0.975]
ar.L1	-0.0365	0.018	-2.066	0.039	-0.071	-0.002
ar.L2	0.7026	0.015	47.284	0.000	0.674	0.732
ma.L1	-0.1227	0.017	-7.126	0.000	-0.156	-0.089
ma.L2	-0.8744	0.017	-50.789	0.000	-0.908	-0.841
sigma2	2.271e+04	21.509	1055.912	0.000	2.27e+04	2.28e+04

Ljung-Box (L1) (Q):	0.66	Jarque-Bera (JB):	108025395.80
Prob(Q):	0.42	Prob(JB):	0.00
Heteroskedasticity (H):	5.11	Skew:	13.95
Prob(H) (two-sided):	0.00	Kurtosis:	453.60

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

ARIMA: MAE=76.8672, RMSE=480.4429, MAPE=90.41%

Рисунок 5 – Подбор параметров для ARIMA

Были вычислены три метрики:

- MAE (Mean Absolute Error): средняя абсолютная ошибка
- RMSE (Root Mean Squared Error): среднеквадратичная ошибка (чувствительна к выбросам)
- MAPE (Mean Absolute Percentage Error): средняя процентная ошибка

Таблица 1 – Сравнение моделей

Модель	MAE	RMSE	MAPE
Naive	76.12	482.15	66.49%
MA7	75.92	481.25	77.16%
MA30	76.61	482.57	62.86%
ARIMA(2,1,2)	76.87	480.44	90.41%

Из таблицы 1 видно, что:

Все модели показывают близкие результаты (MAE ~76, RMSE ~482)

- ARIMA показывает наименьший RMSE (480.44) среди всех моделей

- Однако MAPE у ARIMA самый высокий (90.41%) — модель чувствительна к выбросам
- ARIMA лучше отслеживает динамику данных благодаря учету автокорреляции (рис. 6)




Рисунок 6 – Сравнение моделей

3.3 Обнаружение аномалий

Для обнаружения аномалий были опробованы 3 метода (рис. 7)



Рисунок 7 – Обнаружение аномалий

График Z-score:

Красные точки — аномалии. Пунктирные линии — верхняя и нижняя границы ($\text{mean} \pm 3 \cdot \text{std}$). Видно, что выделяются только самые экстремальные пики.

График IQR:

Оранжевые точки — аномалии. Пунктирные линии — границы IQR. Много точек за пределами границ, так как данные имеют длинные "хвосты".

График ARIMA:

Зеленые точки — аномалии по ошибке прогноза. Находит точки, где фактическое значение сильно отклоняется от прогноза. Хорошо выявляет неожиданные всплески.

В сравнении (рис. 8):

- Z-score хорошо находит экстремальные пики (например, значения $> 10,000$) и чувствителен к глобальным выбросам

- IQR выделяет слишком много точек — многие из них не являются аномалиями в контексте временного ряда. IQR лучше работает с распределением данных.
- Ошибка ARIMA находит сбалансированное количество аномалий — точки, где поведение ряда необычное, отклоняется от прогноза.
- Модель ARIMA хорошо справляется с прогнозированием, но может не учитывать внешние факторы.




Рисунок 8 – Сравнение методов обнаружения аномалий

Таблица 2 – Сравнение методов обнаружения аномалий

Метод	Найдено аномалий	% от данных
Z-score (порог=3)	99	0.62%
IQR	1250	7.86%
Ошибка ARIMA	192	1.21%

Из таблицы 2:

- Z-score показывает, на сколько стандартных отклонений значение отклоняется от среднего. В данном случае значение 99 — это очень большое отклонение. Для стандартного нормального распределения такое значение соответствует крайне редкой случайности (менее 0.62% случаев). Это сильный выброс (аномалия), который может исказить результаты анализа.
- IQR (Interquartile Range, межквартильный размах) — это разница между третьим и первым квартилями, она показывает разброс средней половины

данных. Значение 1250 указывает на очень широкий разброс значений в центральной части выборки. Это тоже признак наличия сильных выбросов, которые могут влиять на среднее и стандартное отклонение, используемые при расчёте Z-score.

- Ошибка модели ARIMA — это метрика точности прогнозов. Значение 192 означает, что средняя абсолютная ошибка прогнозов составляет 1.21%. Это довольно хороший показатель, особенно для временных рядов, где такие ошибки встречаются нередко.

Эти три показателя вместе указывают на одну и ту же проблему: в наших данных есть очень сильные выбросы. Они могут быть вызваны специфическими событиями. Методы дополняют друг друга: каждый находит разные типы аномалий. Z-score лучше для поиска глобальных выбросов. Ошибка ARIMA лучше для поиска локальных отклонений. Рекомендация: использовать комбинацию методов для лучших результатов.

3.4 Оценка с использованием разметки NAB

Для оценки качества методов использовалась реальная разметка аномалий из датасета NAB [10]. В разметке для «Twitter_volume_AAPL.csv» указаны 4 аномальные точки (с учетом временного окна в 30 минут получено 52 аномальные точки).




Рисунок 9 – Реальные аномалии в данных (из разметки NAB)

Таблица 3 – Сравнение методов обнаружения аномалий на реальных данных об аномалиях

	Precision	Recall	F1-Score	True Positives	False Positives	False Negatives	True Negatives
Z-score	0.3131	0.5962	0.4106	31.0	68.0	21.0	15782.0
IQR	0.0384	0.9231	0.0737	48.0	1202.0	4.0	14648.0
ARIMA error	0.1302	0.4808	0.2049	25.0	167.0	27.0	15683.0

Из таблицы 3:

Z-SCORE (F1-Score: 0.4106) – лучший:

- Precision 31.31%: из 99 найденных аномалий 31 действительно аномальные
- Recall 59.62%: найдено почти 60% всех реальных аномалий
- Хороший баланс между точностью и полнотой
- 68 ложных тревог (False Positives)
- 21 пропущенная аномалия (False Negatives)

IQR (F1-Score: 0.0737) – худший:

- Recall 92.31%: находит почти все реальные аномалии (48 из 52)
- Precision всего 3.84%: огромное количество ложных тревог (1202!)

- Слишком чувствителен, находит слишком много "аномалий"
- Неприменим на практике из-за большого числа ложных срабатываний

ARIMA (F1-Score: 0.2049):

- Precision 13.02%: лучше чем IQR, но хуже чем Z-score
- Recall 48.08%: находит около половины аномалий
- Пропускает больше аномалий чем другие методы
- Средний баланс между точностью и полнотой

Для данного типа данных (объем твитов) Z-score оказался наиболее эффективным (рис. 10), так как:

- Аномалии в социальных медиа часто являются глобальными выбросами
- Данные имеют высокую волатильность, но Z-score хорошо справляется с

ЭТИМ

- Порог 3 сигмы дает хороший баланс между обнаружением и ложными тревогами (рис. 11)

Для реального мониторинга социальных медиа рекомендуется:

- Использовать Z-score с порогом 3 как основной метод
- Для повышения Recall – снизить порог до 2.5
- Для повышения Precision – повысить порог до 3.5
- Комбинировать несколько методов (IQR для предварительного отбора + Z-score для фильтрации)




Рисунок 10 – Матрица корреляций




Рисунок 11 – Анализ ошибок

4. Ограничения и возможные улучшения

4.1 Ограничения

1. Модели не учитывают внешние факторы (день недели, праздники, новости)
2. Методы обнаружения аномалий используют простые статистические пороги
3. ARIMA не учитывает сезонность на уровне дней недели
4. Данные только по одной компании, нет сравнения с конкурентами

4.2 Предложения по улучшению

1. Модели прогнозирования: добавить SARIMA для учета сезонности, использовать LSTM
2. Обнаружение аномалий: Z-score с порогом 3 как основной метод или IQR для предварительного отбора (высокий Recall), затем применять Z-score для фильтрации (повышение Precision), автоматический подбор порогов, использование Isolation Forest [8], ансамблирование методов
3. Визуализация: создать интерактивный дашборд с Plotly или Streamlit

Заключение

В ходе выполнения учебной практики был разработан прототип системы прогнозирования и обнаружения аномалий во временных рядах на основе данных Numenta Anomaly Benchmark.

Ключевые результаты:

1. Прогнозирование: модель $ARIMA(2,1,2)$ показала наилучший результат ($RMSE = 480.44$) благодаря учету автокорреляции.
2. Обнаружение аномалий: метод Z -score с порогом 3 оказался наиболее эффективным ($F1\text{-Score} = 0.4106$), т. к. выявляет глобальные выбросы в данных.
3. IQR находит больше аномалий, но может быть излишне чувствительным.
4. Практическая применимость: разработанный прототип может использоваться для мониторинга социальных медиа

Работа выполнена в полном соответствии с заданием, все этапы анализа реализованы в Jupyter Notebook, результаты сохранены в репозитории.

Репозиторий: <https://github.com/DarinaStepanova/time-series-anomaly-practice.git>

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Numenta Anomaly Benchmark (NAB). OpenBenchmarking.org. URL: <https://openbenchmarking.org/performance/test/pts/numenta-nab/>
2. Kotu, V., Deshpande, B. (2019). Autoregressive Integrated Moving Average. In: Data Science (Second Edition). ScienceDirect.
3. DetectK Detectors Documentation. PyPI. URL: <https://pypi.org/project/detectk-detectors/>
4. Detecting Anomalies in Social Media Volume Time Series. Towards Data Science (Archived). URL: <https://towardsdatascience.com/detecting-anomalies-in-social-media-volume-time-series-9cae614a11d0>
5. Ok, M., Klüttermann, S., Müller, E. (2024). Exploring the Impact of Outlier Variability on Anomaly Detection Evaluation Metrics. arXiv:2409.15986.
6. Evaluating Real-time Anomaly Detection Algorithms – the Numenta Anomaly Benchmark. IOP Science. URL: <https://iopscience.iop.org>
7. Nau, R. (2020). Issues in estimating parameters in ARIMA models. Duke University. URL: <https://people.duke.edu/~rnau/arimest.htm>
8. quickOutlier: Comprehensive Toolkit for Anomaly Detection. CRAN R Project. URL: <https://cran.r-project.org/web/packages/quickOutlier/>
9. Ghorbani, R., Reinders, M.J.T., Tax, D.M.J. (2024). PATE: Proximity-Aware Time series anomaly Evaluation. arXiv:2405.12096.
10. Numenta Anomaly Benchmark (NAB). GitHub Repository. URL: <https://github.com/numenta/NAB>
11. Nau, R. Introduction to ARIMA: nonseasonal models. Duke University. URL: https://people.duke.edu/~rnau/Decision411_2007/411arim.htm
12. Ahmad, S., Lavin, A., Purdy, S., & Agha, Z. (2017). Unsupervised real-time anomaly detection for streaming data. Neurocomputing, Available online 2 June 2017, ISSN 0925-2312.
13. Lavin, A., Ahmad, S. (2015). Evaluating Real-time Anomaly Detection Algorithms – the Numenta Anomaly Benchmark. 14th International Conference on Machine Learning and Applications (ICMLA).